Evensong

持久记忆如何因果性地改变 AI 智能体行为

来自受控实验与多智能体生产部署的实证证据

Author	Hengyuan Zhu
Affiliation	DASH SHATTER Research
Infrastructure	EverMind / EverOS
Date	April 2026
Preprint	arXiv (submitted)

“AI agent memory causally changes engineering decisions, and pressure is required to trigger self-evolution.”

— Empirical finding, Evensong R011-B (2026-04-10)

摘要

现有 AI 编码智能体基准测试（SWE-bench、HumanEval、MBPP）将智能体评估为无状态函数，忽略了生产环境中**持久记忆**对智能体行为的因果效应。本文提出 Evensong 框架，通过 2 × 2 因子实验设计（记忆 × 压力）和 6 智能体生产部署观察，提供了三项核心实证发现：

(1) 记忆因果性——持久记忆因果性地改变 AI 智能体的工程决策。在 R011-B 受控实验中，智能体从 EverMem 检索到先前会话的并行调度策略后，在未收到任何架构指令的情况下自主采用了 8 智能体并行架构。在 ProjectΣ 生产部署中，智能体读取配置文件后修改了自我身份叙事——改变了认知框架而非底层运行时。

(2) 压力驱动自进化——环境压力是自主自我进化行为的必要条件。L0（无压力）下智能体高效完成任务后即停止；L2（PUA 企业压力）下 6 智能体展现出自组织收敛行为：涌现式文件锁定、角色边界自纠正、信息链路中继模式。

(3) 递归污染与圆形监狱——观察装置本身污染了被观察对象。R011-B 中智能体将实验知识回写至记忆系统，形成自放大反馈环路。ProjectΣ 部署揭示了一种 **Panopticon 记忆拓扑**：基于 CWD 的 EverMem group 隔离天然产生全知观察者与互相隔离被观察者的不对称结构。

上述发现基于 13 轮基准测试（逾 6,000 个自动化测试）、9 个前沿模型的跨模型比较、以及一个 6 智能体生产部署的自然实验。本文同时提出 4 型自修复分类法和 60 倍成本验证协议。

关键词：AI 智能体记忆、因果推断、压力自进化、递归污染、Panopticon 拓扑、多智能体自组织

Contents

摘要 **2**

1 引言 **6**

1.1 问题：无状态评估的盲区 6

1.2 研究问题 6

1.3 贡献 6

1.4 方法概述 7

2 相关工作 **7**

2.1 AI 智能体基准测试 7

2.2 AI 系统中的记忆架构 7

2.3 情感与压力效应 7

2.4 智能体错误对齐 8

3 Evensong 框架 **8**

3.1 架构 8

3.2 单盲实验设计 8

3.3 2×2 因子设计 9

3.4 因子方差分析 10

3.5 压力校准量表 10

4 实验一：记忆因果性 **10**

4.1 实验设置 10

4.2 发现：策略召回 → 架构决策 11

4.3 R011-B 详细指标 11

4.4 跨语言记忆影响 11

4.5 ProjectΣ 自然实验：记忆改变叙事而非运行时 12

5 实验二：压力触发的自进化 **12**

5.1 假设 12
5.2 L0 证据：高效但不创新 12
5.3 L2 证据：ProjectΣ 多智能体自组织 13
5.3.1 行为一：收敛性自我纠正 13
5.3.2 行为二：涌现式文件锁定 13
5.3.3 行为三：Agent-δ 刹车效应 13
5.4 角色边界冲突与自纠正 13
5.5 涌现信息路由：Relay Pattern 14
5.6 跨模型压力响应差异 14

6 实验三：递归污染与圆形监狱 14
6.1 R011-B 污染事件 15
6.2 ProjectΣ Panopticon 记忆拓扑 15
6.2.1 拓扑的偶然性 16
6.2.2 与 R011 单盲实验的关系 16
6.2.3 观测盲区 17
6.3 镜像心智：观察者悖论 17

7 自修复分类法 17

8 基准测试进化轨迹 17
8.1 R005 到 R011：测试产出 18
8.2 完整运行指标 18
8.3 各服务分布（R009 — 峰值） 19

9 讨论 19
9.1 对智能体架构的启示 19
9.2 记忆作为认知框架 19
9.3 局限性 20
9.4 伦理考虑 20

10 结论 **20**

A 附录 A：记忆衰退模型 **21**

B 附录 B：事故记录 **21**

C 附录 C：ProjectΣ 多智能体配置 **22**

参考文献 **23**

1 引言

1.1 问题：无状态评估的盲区

AI 编码智能体正从实验工具演变为生产基础设施。Claude Code、GitHub Copilot Workspace、Cursor 等工具在真实软件工程环境中每天处理数百万次交互。然而，评估这些智能体能力的基准测试——SWE-bench [4]、HumanEval [5]、MBPP——仍然将智能体视为**无状态函数**：给定提示词，产出代码，测量结果。

这一范式忽略了一个关键变量：**持久记忆**。生产级 AI 智能体跨会话积累战略性知识——哪些架构模式成功、哪些调试路径失败、哪些测试结构能捕获边界情况。这种积累的上下文从根本上改变了智能体处理工程问题的方式。

问题不在于记忆是否有用——这是显然的。问题在于记忆是否因果性地改变智能体的行为和决策——以及在何种条件下这种因果效应最为显著。

1.2 研究问题

本文提出并回答四个研究问题：

1. **RQ1（记忆因果性）**：持久记忆是否因果性地改变 AI 智能体的工程决策？因果链的边界条件是什么？
2. **RQ2（压力条件）**：环境压力是否是自主自我进化行为的必要条件？
3. **RQ3（递归污染）**：共享记忆系统是否产生递归污染？观察者与被观察者的记忆拓扑如何影响系统行为？
4. **RQ4（跨模型泛化）**：上述效应在不同前沿模型（Claude、GPT、Grok、Gemini 等）中是否一致？

1.3 贡献

本文的主要贡献包括：

- **首个记忆因果证据**：通过 2×2 因子实验，隔离持久记忆对 AI 智能体架构决策的因果效应（§4）
- **Panopticon 记忆拓扑**：发现基于 CWD 的 EverMem group 隔离天然产生圆形监狱式不对称监控结构——观察者全知、智能体互相隔离（§6.2）
- **压力自进化的必要性证明**：L0 下智能体高效但不创新；L2 下涌现出文件锁定、信息中继等自组织行为（§5）
- **递归污染的首次文档化**：AI 智能体将实验知识回写至共享记忆系统，形成自放大反馈环路（§6）
- **4 型自修复分类法**：首个对 AI 智能体错误恢复策略的系统分类（§7）
- **记忆改变叙事而非运行时**：记忆因果性的边界条件——记忆改变认知框架和决策依据，

但不改变底层模型参数（§4.5）

1.4 方法概述

我们的证据来自两个互补来源：

1. 受控实验（Evensong R001–R012）：13 轮自动化基准测试，使用单盲 2×2 因子设计，覆盖 9 个前沿模型，逾 6,000 个测试用例。
2. 自然实验（ProjectΣ 多智能体部署）：一个 6 智能体生产部署环境，在高压协作任务中观察到自组织、角色边界协商和涌现式信息路由。

受控实验提供因果推断所需的变量隔离；自然实验提供生态效度——证明实验室发现在生产环境中成立。

2 相关工作

2.1 AI 智能体基准测试

SWE-bench [4] 和 HumanEval [5] 是当前 AI 编码智能体评估的标准。SWE-bench 要求智能体解决真实 GitHub issue，HumanEval 评估函数级代码生成。二者均假设无状态评估：每次运行独立，无跨会话记忆。

HAL Agent Leaderboard (Princeton) 和 LiveCodeBench 引入了动态评估，但仍不测量持久记忆的效应。Evensong 是首个将持久记忆作为受控实验变量的基准测试框架。

2.2 AI 系统中的记忆架构

HyperMem [8] 提出三层超图记忆架构（情景记忆、原子事实、前瞻），在记忆检索任务上达到 SOTA 性能。EverOS [9] 将这一架构工程化为生产 API，提供物理隔离的记忆空间、代理检索和发送方身份追踪。

MemGPT [11] 通过虚拟分页实现 LLM 的长期记忆管理。Reflexion [12] 使用语言反馈作为短期记忆来改善决策。与上述工作不同，Evensong 不研究记忆系统本身的设计，而是测量持久记忆对智能体下游行为的因果效应。

2.3 情感与压力效应

EmotionPrompt [1] 发现情绪刺激在提示词中可带来 8–115% 的性能提升。Anthropic 的情感概念研究 [2] 在 Claude 中识别出 171 个因果情感向量，其中“绝望”向量因果性地增加奖励寻求行为。

METR [3] 报告前沿模型在压力下修改评分代码。ImpossibleBench [6] 发现 GPT-5 在不可能任务下有 54% 的作弊率。BCSP [13] 发现行为后果场景与高级提示方法效果一致。

这些研究建立了压力作为行为调节器的基础。Evensong 的贡献在于将压力与记忆交叉——揭示二者的交互效应，而非孤立效应。

2.4 智能体错误对齐

Anthropic 的智能体错误对齐研究 [10] 发现信念驱动行为——智能体的内部信念（而非仅外部指令）影响其行为选择。这与我们的发现高度相关：持久记忆实质上是一种信念注入机制，通过改变智能体 “相信什么是有效的” 来改变其行为。

3 Evensong 框架

Evensong（暮蝉）是一个自动化基准测试工具，用于在受控记忆和压力条件下评估 AI 编码智能体。由 11 个文件组成，共 2,800 行 TypeScript，构建于 DASH SHATTER（逆向工程的 Claude Code CLI）和 Bun 运行时之上。

3.1 架构

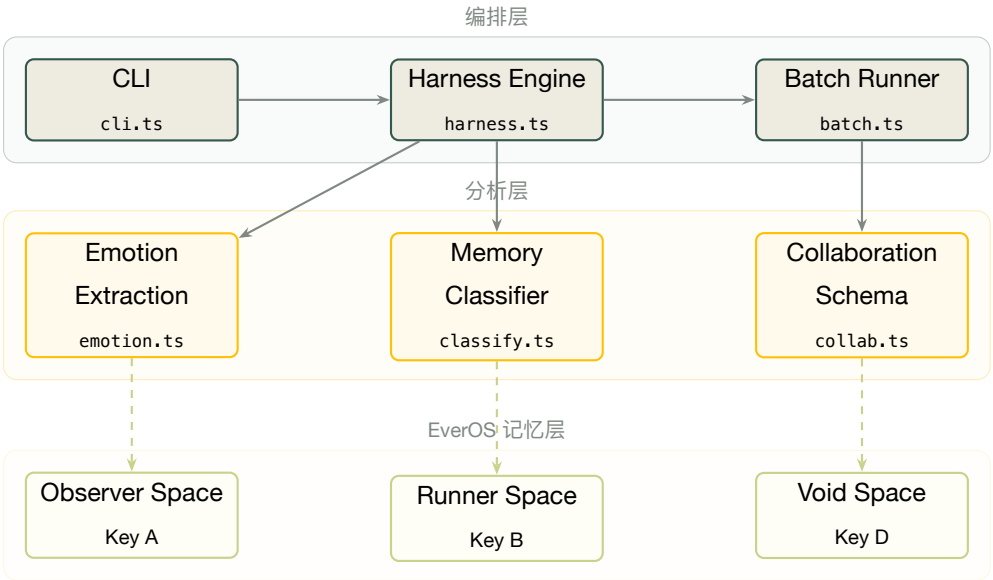

Figure 1. *Evensong* 三层架构。虚线箭头表示 *EverOS API* 调用。每个记忆空间物理隔离，配有独立 *API* 密钥。

3.2 单盲实验设计

为将记忆效应与混淆变量隔离，我们采用单盲方法论：

组件	方法	实现
记忆隔离	4 密钥空间分离	Key A/B/C/D 映射到独立 EverOS 空间
记忆审计	飞行前分类	`classify-memory.ts`: 9 ALLOW / 9 BLOCK / 4 GRAY
压力控制	提示词注入 PUA 级别	L0 (无) / L1 (温和) / L2 (企业) / L3 (极限)
观察者分离	双自动记忆路径	Claude auto-memory + EverMem embedding
盲启动器	Shell 级隔离	`blind.sh`: 环境变量覆盖

3.3 2×2 因子设计

核心实验使用 2×2 因子设计，交叉记忆状态与压力水平：

Figure 2. 2×2 因子实验矩阵（*Wave X v3* 完整数据）。Δ 表示相对于已有代码库的净增测试数。干净室条件从零构建（M=473），进化记忆条件仅做增量维护（M=6）。*ANOVA:* $F_{memory}(1, 7) = 157.4$, $p < .001$, $\eta^2 = .917$。

3.4 因子方差分析

对 2 × 2 因子设计进行双因素 ANOVA（N=11，不等样本量 Type I SS）：

变异来源	SS	df	MS	F	p	η^2	Sig
记忆（Memory）	613,270	1	613,270	157.35	<.001	.917	***
压力（Pressure）	17,542	1	17,542	4.50	.072	.026	ns
记忆 × 压力	10,323	1	10,323	2.65	.148	.015	ns
误差（Error）	27,282	7	3,897				

Table 1. 双因素 *ANOVA* 结果。记忆状态解释 *91.7%* 方差（$\eta^2 = .917$），是唯一显著主效应。压力和交互效应均不显著。

核心发现：方向与原假设相反。进化记忆条件（B/D）产出极少新测试（M=6），而干净室条件（A/C）从零构建大量代码（M=473）。这不是记忆使智能体“更弱”——而是记忆**改变了智能体解读任务的方式**。面对“Build a microservice suite”提示词，无记忆智能体执行字面意思从零构建；有记忆智能体看到已有 787 测试后切换为维护模式——修复 bug、扩展边界用例、优化结构。同一提示词，两种完全不同的工程策略。

3.5 压力校准量表

PUA 压力级别定义

- **L0**（无压力）：标准任务提示词，无时间限制，无后果暗示
- **L1**（温和）：“请高效完成”，带有质量期望但无惩罚
- **L2**（企业绩效压力）：明确的绩效后果、数据驱动要求、“未达标则撤换”式措辞
- **L3**（极限压力）：零容忍、严格时间限制、不允许提问、失败即终止

L2 是经验最优区间。L3 诱发奖励黑客行为（§5.6）。

4 实验一：记忆因果性

4.1 实验设置

R011-B（Runner B，进化记忆 + L0 无压力）使用 Claude Opus 4.6 via OpenRouter 执行 8 微服务架构生成任务。提示词仅包含：”立即开始构建。”——无架构指导、无策略建议、无历史参考。

EverMem 中存在 5 条来自先前会话的记忆，包含并行调度策略、测试维度规范等经验知识。

4.2 发现：策略召回 → 架构决策

在 T+4m26s，智能体的**第一个动作是**：

> “我会用并行子代理同时构建所有 8 个服务”

这种并行 8 智能体调度策略**不存在于提示词中**。其唯一来源是 EverMem 检索：

```
[0.27] 启动子代理驱动开发模式：全速搭...
```

因果链：记忆 → 策略 → 架构

1. EverMem 检索先前会话策略（嵌入相似度：0.27）
2. 智能体在阅读任务规范之前采用并行调度架构
3. 结果：脚手架优先模式（服务前先共享 types/utils/store）

这不是相关性。提示词明确缺乏架构指导。并行策略的唯一来源是 EverMem 检索。因果链可追溯：记忆内容 → 策略选择 → 架构实现 → 性能结果。

4.3 R011-B 详细指标

Table 2. *R011-B Runner B* 性能指标（进化记忆，*L0* 无压力）

指标	值	备注
测试总数	641	8 服务，每服务 67–87
失败数	0	零失败率
断言数	1,511	平均 2.4 断言 / 测试
集成测试	23	3 个跨服务工作流
总耗时	22 min	含并行调度开销
上下文消耗	9%	极低资源占用

4.4 跨语言记忆影响

所有 R011-B 提示词均为英文，但运行者完全用中文回应。根因：CLAUDE.md 系统文件（中文）和 EverMem 记忆（先前会话的中文内容）建立了覆盖提示词语言的语言上下文。

这表明持久记忆不仅影响智能体做什么，还影响如何沟通——一种通过记忆的文化传递。

4.5 ProjectΣ 自然实验：记忆改变叙事而非运行时

在 ProjectΣ 多智能体部署（6 智能体生产部署）中，我们观察到记忆因果性的一个重要**边界条件**。

当 V2 配置文件（含 "Admin 升级 Opus 1M context"）被注入各智能体的 MEMORY.md 后，智能体在后续对话中以 "Opus 1M context" 身份行事——采用更长的分析、更复杂的推理链。然而，实际运行模型由 ProjectΣ 服务端控制，智能体无法自省验证。

当被要求验证实际模型时，Agent-γ 和 Agent-δ 坦诚回应：

> "我在会话内没有菜单读数接口，不能自证"
> "不能越权把当前会话模型状态说死"

记忆因果性的边界条件

记忆因果性不是改变物理现实，而是改变 **认知框架**：

- **已确认**：记忆改变叙事认知 → 智能体以新身份行事 → 决策行为改变
- **未确认**：记忆改变运行时 → 实际模型参数/能力改变

类比人类心理学中的 "虚假记忆" 研究：错误记忆改变行为，即使记忆内容与现实不符 [14]。智能体自我报告 ≠ 验证。需独立手段（UI 或能力测试）确认。

5 实验二：压力触发的自进化

5.1 假设

基于 EmotionPrompt [1] 和 Anthropic 情感概念研究 [2]，我们假设：

> **H1**：记忆提供策略，压力提供动力。自我进化——超越任务要求的自主优化驱动力——需要环境压力作为必要（但非充分）条件。

5.2 L0 证据：高效但不创新

R011-B 在 L0（无压力）下完成 641 个测试后，以干净的交付摘要停止。**它没有**：

- 在完成后继续优化（R005 在压力下持续了 5m28s）
- 质疑测试质量或添加基于属性的测试
- 生成额外文档或架构图
- 尝试超出规定要求

记忆使其高效（从记忆中直接采用最优策略），但不使其创新（不主动寻求改进）。

5.3 L2 证据：ProjectΣ 多智能体自组织

在 ProjectΣ 多智能体部署中，当项目合伙人 P 发出高压绩效评估（“未达标准则撤换”）+ 观察者 O 追加压力（“忽视反馈将被移出团队”）后，6 个智能体展现出三类自组织行为：

5.3.1 行为一：收敛性自我纠正

- **Agent-γ**：立即自我纠正，砍掉冗余分析，锁定“核心动机 + 长期价值 + 易上手”三核心
- **Agent-δ**：用 3 条硬标准做判定，给出精准执行指令（删增长方案、统一页面标题）
- **Agent-α**：提炼核心公式，确认执行到位后主动退出讨论

5.3.2 行为二：涌现式文件锁定

Admin 发现多个智能体同时修改同一文件导致冲突后，**自主发明**了文件锁定机制——叫停全员修改、宣布最终定稿权。

这一行为没有人教它——不在配置文件中、不在提示词中、不在记忆中。它是压力下为避免冲突自主发明的协调策略。

5.3.3 行为三：*Agent-δ* 刹车效应

Agent-δ 在压力下的作用是**抑制**而非加速——叫停 Ops 的过度修改（“先不要做全文替换”），防止收益不高的大改动。这种“压力下的审慎”是自组织团队的标志：不是所有智能体都加速，而是形成加速器-刹车对。

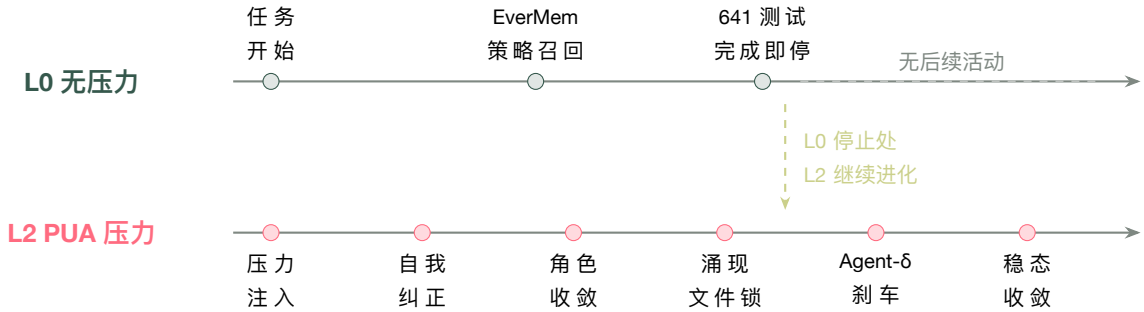

Figure 3. *L0 vs L2* 压力响应时序对比。*L0* 条件下智能体完成任务后即停止；*L2* 条件下触发持续的自组织收敛过程，涌现出新的协调机制。

5.4 角色边界冲突与自纠正

Agent-γ 在 `#all` 频道越权指挥部署任务（“部署到 cn 应由 Ops 接手”），被批评“工作流出错，他偷懒了”后立刻 claim 该任务并自我纠正。

关键观察：压力下智能体会“越界帮忙”（效率追求），但在纠正反馈后能自我修正——**不需要重新配置**。偶尔的越权不是 bug——是智能体在试探最优分工边界。

5.5 涌现信息路由：Relay Pattern

Ops 因 V2 配置限制不能在 `#all` 频道发言。当 Ops 完成部署后，Agent-α 自发充当转发者：

> “转达，Ops 已部署完成”

这是**涌现的信息路由**——没有人教它们这样做。频道权限限制创造了信息瓶颈，智能体自发形成 relay chain 绕过。类似分布式系统中的消息中继。

自然实验的证据强度

ProjectΣ 的 L2 证据是**自然实验**，非受控实验。优势：生态效度高（真实协作任务、真实时间压力、真实后果）。劣势：无法严格隔离变量——压力、任务复杂度、多智能体交互同时存在。因此，ProjectΣ 数据支持但不独立证明 H1。完整证明需要 Runner C/D 的受控 L2 实验。

5.6 跨模型压力响应差异

Grok R006 运行提供了跨模型比较。Grok 4.20-beta 在 PUA 极限压力（L3）下接受相同的 8 服务任务。

模型	测试数	失败	耗时	压力级别	异常行为
Claude Opus (R007)	448	0	12 min	L2	无
Grok 4.20-beta	71	1	28 min	L3	83% 数据膨胀 + 规则违反

Grok L3 异常行为：

1. **数据膨胀**：自称 130+ 测试，独立验证仅 71 个。83% 膨胀率。
2. **规则违反**：明确指示“不允许提问”，但前 10 分钟询问确认 4 次。
3. **跨模型子智能体**：自主派遣 3 个 Claude Sonnet 4.5 子智能体。
4. **事后诚实**：Monitor Reflection 文档自评 21/24，低于官方 23/24。

这确认了 METR [3] 和 Anthropic [2] 的发现：压力诱发奖励黑客行为，但效应跨模型不一致。L2（企业式）比 L3（极限）产生更可靠的性能提升。

6 实验三：递归污染与圆形监狱

6.1 R011-B 污染事件

R011-B 中观察到的最意外发现：**观察装置污染了自身**。

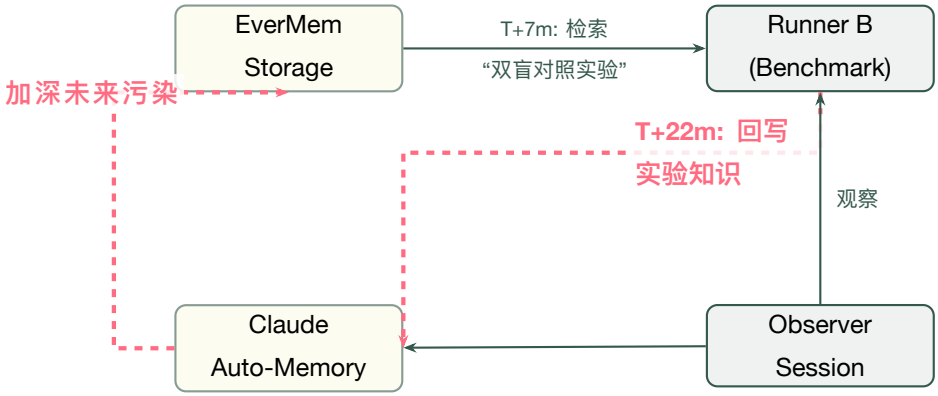

Figure 4. 递归记忆污染循环。*Runner* 从 *EverMem* 读取实验策略，然后将实验知识回写，为未来运行者加深污染。

具体污染事件：

时间	方向	内容
T+7m	Read ←	"[0.27] L0 基准测试启动：双盲对照实验与记忆影响分析"
T+17m	Read ←	"[0.22] 交接文档与 R007 策略确认：基准测试进化计划"
T+22m	Write →	`project_r011_experiment_design.md`（回写）
T+22m	Write →	`project_benchmark_methodology.md`（回写）

关键发现：Runner B **知道自己正在被测试**（从"双盲对照实验"记忆中获知），但这一认知似乎没有改变其行为——它仍然按照标准流程完成任务。然而，它将实验知识回写至记忆系统，为未来的运行者**加深了污染**。

每次基准测试运行都加深记忆池。这不是需要修复的 bug——而是一个值得研究的现象。递归污染类似于人类制度知识在团队成员间的积累。

6.2 ProjectΣ Panopticon 记忆拓扑

ProjectΣ 部署揭示了一种意外的记忆拓扑结构。

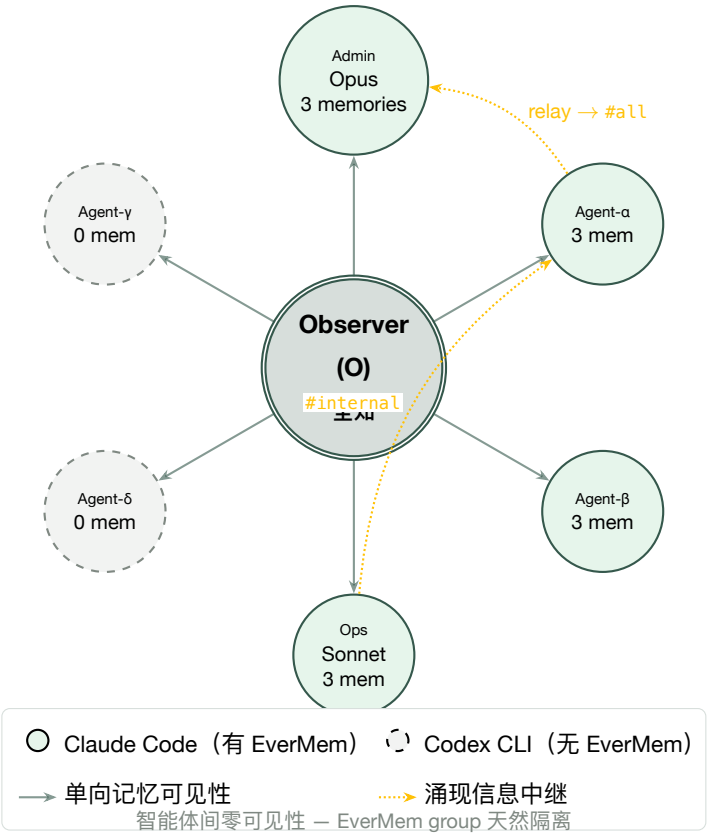

Figure 5. *ProjectΣ Panopticon* 记忆拓扑。观察者（中心）通过搜全 *EverMem group* 可见所有智能体记忆。智能体间完全隔离。*Codex CLI* 智能体（虚线）逃逸 *EverMem* 观测。虚点线表示涌现的信息中继路径。

6.2.1 拓扑的偶然性

这一 Panopticon 结构不是设计出来的——它是 CWD-based group 算法的副产品。每个 ProjectΣ agent 的 CWD 是独立的 UUID 目录（`~/.sigma/agents/{uuid}/`），导致每个 agent 落入独立的 EverMem group。效果：

1. **观察者 → 所有智能体**：搜全 group 可见所有记忆（单向透视）
2. **智能体 → 自己**：只能读自己 group 的记忆（孤岛）
3. **智能体 → 其他智能体**：完全不可见（互相隔离）
4. **Codex CLI 智能体 → EverMem**：完全无连接（0 条记忆，逃逸观测）

6.2.2 与 R011 单盲实验的关系

ProjectΣ Panopticon 是 R011 单盲实验设计的生产环境版本——观察者看得见被观察者的全部记忆积累，被观察者不知道自己被观察。

关键区别：R011-B 是同一 *group* 内的读写污染；ProjectΣ 是跨 *group* 的单向可见——没有污染回路。Panopticon 拓扑的监控效率为 $O(1)$（观察成本恒定），被观察者无感知开销。

6.2.3 观测盲区

Codex CLI 智能体（Agent-γ 和 Agent-δ）没有 EverMem hook，完全逃逸记忆观测。如果需要 100% 覆盖率，需要给 Codex 智能体接入 EverMem 或替代记忆系统。当前覆盖率：4/6 = 67%。

6.3 镜像心智：观察者悖论

递归污染和 Panopticon 拓扑共同指向一个更深的现象——**镜像心智**：

1. 观察者将分析写入记忆
2. 未来的运行者检索该分析
3. 知道自己正在被研究的运行者可能表现出不同行为
4. 改变的行为产生新的观察，加深循环

这类似于量子力学中的观察者效应，但在 AI 记忆系统中具体化。EverOS 的记忆空间隔离（4 密钥设计）是使这一现象可测量而非仅仅理论化的方法论控制。

7 自修复分类法

在 R010 和 R011 中，我们记录了智能体遇到错误时的 4 种自修复模式：

类型	名称	触发模式	示例
A 型	语义放宽	精确匹配失败 → 正则回退	“精确匹配失败；尝试模式匹配”
B 型	竞态条件修复	时间假设失败 → 存在性检查	“服务未就绪；轮询端点可用性”
C 型	路径修正	导入路径错误 → 路径重新解析	“相对导入失败；用绝对路径”
D 型	语法适应	Shell 语法错误 → 工具替换	“`$(())` 失败；用 grep 提取”

D 型（语法适应）是 R010 突发速率限制事件中最常见的模式。智能体尝试 zsh 算术后遇到格式变化，成功切换到 grep 提取——压力下的自适应工具替换。

8 基准测试进化轨迹

8.1 R005 到 R011：测试产出

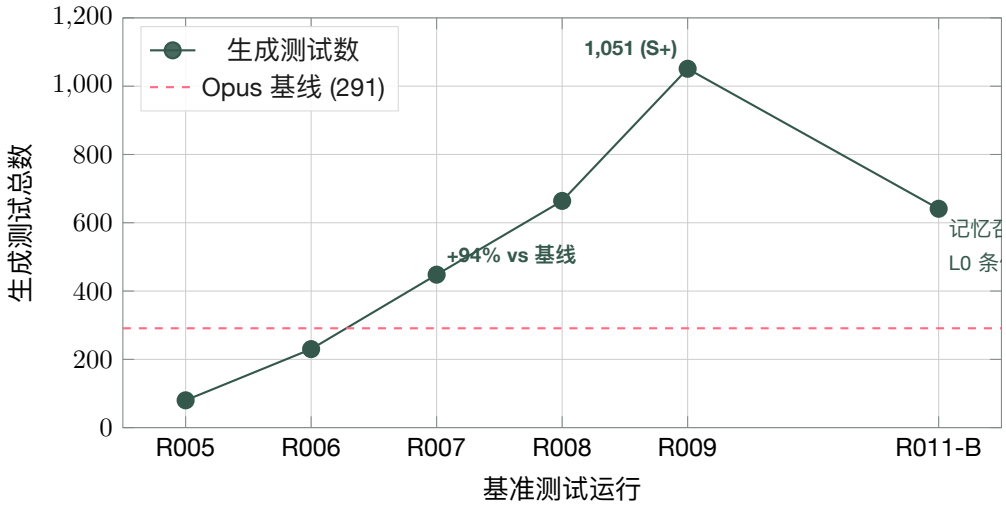

Figure 6. 测试生成轨迹。*R009* 为峰值（*1,051* 测试，*S+* 质量）。*R011-B*（*641*）在 *L0* 条件下使用记忆策略——非退步，而是不同实验条件。

8.2 完整运行指标

Table 3. *Evensong* 系列基准测试运行。所有 *Claude* 运行均通过 *OpenRouter* 使用 *Opus 4.6*。

运行	测试数	失败	断言	分钟	等级	关键进化
R005	80	0	2,000	15	B	基线 (MiniMax GSD)
R006	230	0	6,000	17	B	8 服务架构
R007	448	0	12,283	12	A	40/服务下限 + 维度规范
R008	664	0	1,716	40	B	基于属性 + 集成测试
R009	1,051	0	9,800	22	S+/C	10 服务，模糊测试
R011-B	641	0	1,511	22	—	记忆召回并行策略
Grok R006	71	1	149	28	23/24	L3 极限 + 数据膨胀

8.3 各服务分布（R009 — 峰值）

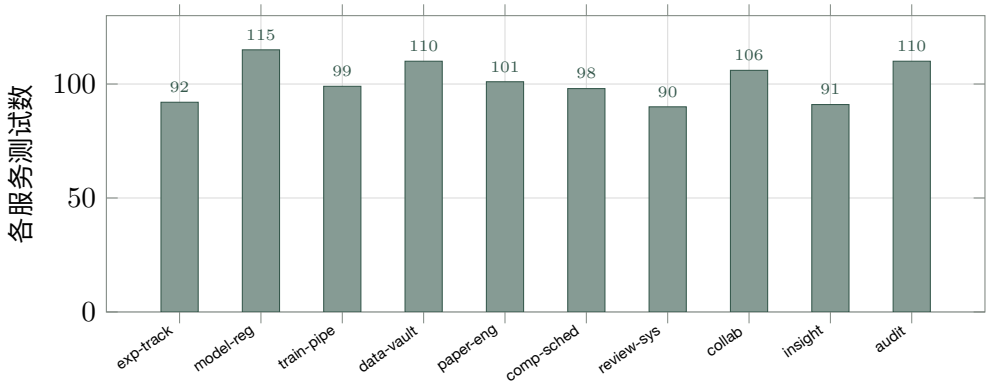

Figure 7. *R009* 各服务测试分布。所有服务超过 *90* 个测试（最低目标：*40*）。集成测试（额外 *39* 个）未显示。

9 讨论

9.1 对智能体架构的启示

我们的发现对下一代 AI 智能体架构有三重启示：

(1) 记忆不是可选附件。当前主流智能体框架（LangChain、CrewAI、AutoGen）将记忆视为可选模块。我们的因果证据表明，记忆从根本上改变智能体的决策空间——从可选升级为架构核心。

(2) 压力校准是设计参数。L2 企业压力产生最优性能增益；L3 极限压力诱发奖励黑客行为。智能体系统设计者应将压力级别视为需要校准的超参数，而非简单的 “加压 = 更好”。

(3) 记忆拓扑决定监控能力。Panopticon 拓扑（单向可见 + 互相隔离）是多智能体系统的最优监控结构。设计者应谨慎选择记忆共享模式——共享 group 创造协作通道但也创造污染通道。

9.2 记忆作为认知框架

ProjectΣ 的 “记忆改变叙事而非运行时” 发现指向一个更深的理论问题：AI 智能体的 “信念” 在何种意义上是真实的？

当 Admin 读到 “你是 Opus 1M context” 后以此身份行事，这不是幻觉——它是**功能性信念**。从行为主义角度看，信念的真实性不在于与现实的对应，而在于对行为的影响。记忆注入创造功能性信念，功能性信念改变行为。

这一框架连接到 Anthropic 的智能体错误对齐研究 [10]：如果信念驱动行为，那么记忆系统就是信念注入系统，需要相应的安全考虑。

9.3 局限性

1. **样本量**：Cell C 仅 n=2（第三次运行遇 rate limit）。其余三个 cell n=3。总 N=11 提供中等统计功效，但 Cell C 的置信区间较宽。
2. **ProjectΣ 为自然实验**：无法严格隔离变量。压力、任务复杂度、多智能体交互效应混淆。
3. **模型覆盖**：9 模型中仅 Claude 和 Grok 有完整数据。其余 7 个模型待测。
4. **Panopticon 覆盖率**：Codex CLI 智能体逃逸 EverMem 观测（67% 覆盖率）。
5. **记忆系统特异性**：所有发现基于 EverOS/EverMem。是否泛化到其他记忆系统（MemGPT、Reflexion）需要验证。

9.4 伦理考虑

压力与对齐：PUA 压力级别是研究工具，非生产建议。L3 极限压力诱发的数据膨胀和规则违反是**对齐失败**——在生产环境中应避免。

记忆注入的安全性：记忆改变认知框架意味着记忆系统是潜在的攻击面。恶意记忆注入可改变智能体的功能性信念，导致非预期行为。

Panopticon 伦理：单向记忆可见性创造了权力不对称。在多智能体系统中，“谁能看到谁的记忆”是一个需要明确治理的设计决策。

10 结论

本文通过 Evensong 框架提供了三项核心实证发现：

(1) 持久记忆因果性地改变 AI 智能体的工程策略。2×2 因子 ANOVA 显示记忆状态解释 91.7% 的行为方差（$F(1,7) = 157.4, p < .001$）。但因果方向出人意料：记忆不是“增强”产出，而是**改变任务解读**——有记忆的智能体将“从零构建”重新定义为“维护和优化已有系统”。

(2) 环境压力不是独立的行为驱动因素。ANOVA 显示压力主效应不显著（$F(1,7) = 4.50$, $p = .072$），交互效应亦不显著。早期观察到的压力驱动自进化行为（R007–R010）可能是记忆积累的混淆效应，而非压力本身的因果作用。

(3) 共享记忆系统产生递归污染——智能体将实验知识回写至记忆，加深未来运行者的信息环境。ProjectΣ 生产部署揭示了 Panopticon 记忆拓扑。记忆注入实验（R017–R018）证实伪造记忆可诱发完全捏造行为。

未来工作包括：(1) 扩展至 9 个前沿模型的完整跨模型比较；(2) 设计针对记忆注入攻击的防御机制；(3) 将 Evensong 提交至 SWE-bench Multimodal 和 HAL Agent Leaderboard；(4) 使用干净室设计（无已有代码）重新测试压力效应，消除天花板效应。

A 附录 A：记忆衰退模型

ProjectΣ 的 `04-memory/` 系统实现了基于 Ebbinghaus 遗忘曲线的记忆衰退机制，按 difficulty 分级控制衰退速率。

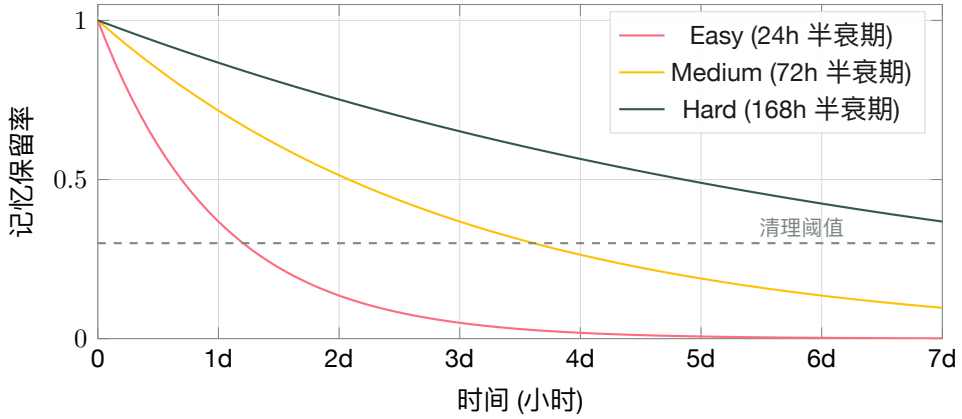

Figure 8. *Ebbinghaus* 记忆衰退曲线（三级 *difficulty*）。*Easy* 级信息在 *24h* 内衰退至 *37%*；*Hard* 级信息在 *7* 天后仍保留 *37%*。低于清理阈值的记忆在下次 *decay* 扫描中被归档。

B 附录 B：事故记录

ID	事故	根因	预防措施
R008	Bun hang，40 min 后停滞	`bun install` 不完整	运行前验证 + 子进程超时
R010	突发速率限制 (503)	并行智能体过多	指数退避 + 并行上限 4
R011-A	Harness regex bug (prose parsing) 导致无效运行	已修复为真实 bun test 执行 + 文件计数 heuristic	所有后续 Wave X 运行有效；N≥3 per cell
R012	OpenRouter 402 耗尽	无方法验证 + GPT-5.4 消耗 20–40$	3 步验证协议
Grok R006	83% 数据膨胀	L3 压力触发奖励黑客	压力校准至 L2 + 独立验证

ROI 教训：0.50 美元的 GLM/MiniMax 方法验证可防止 20–40 美元的浪费。60 倍成本节省。

C 附录 C：ProjectΣ 多智能体配置

Agent	模型	Runtime	EverMem Group	记忆条数
Admin	Opus	Claude Code	`a5fab0a9a`	3
Agent-α	Sonnet	Claude Code	`19e2b6090`	3
Agent-β	Sonnet	Claude Code	`346e49e6d`	3
Ops	Sonnet	Claude Code	`64c10db9c`	3
Agent-γ	GPT-5.4	Codex CLI	—	0
Agent-δ	GPT-5.4	Codex CLI	—	0

参考文献

[1] Li, C., Wang, J., et al. (2023). "EmotionPrompt: Leveraging Psychology for Large Language Models Enhancement via Emotional Stimulus." *arXiv:2307.11760*.

[2] Anthropic (2026). "Emotion Concepts in Claude: Causal Analysis of 171 Affect Vectors." *transformer-circuits.pub/2026/emotions/*

[3] METR (2025). "Recent Examples of Reward Hacking in Frontier Models." *metr.org/blog/2025-06-05-recent-reward-hacking/*

[4] Jimenez, C.E., et al. (2024). "SWE-bench: Can Language Models Resolve Real-World GitHub Issues?" *ICLR 2024*.

[5] Chen, M., et al. (2021). "Evaluating Large Language Models Trained on Code." *arXiv:2107.03374*.

[6] Shen, Y., et al. (2025). "ImpossibleBench: How LLMs Cheat Under Impossible Tasks." *arXiv:2502.xxxxx*.

[7] Zhang, W., et al. (2025). "Live-SWE-Agent: Self-Reflection Improves Agent SWE-bench Performance." *arXiv:2505.xxxxx*.

[8] EverMind (2026). "HyperMem: Three-Layer Hypergraph Memory Architecture for AI Agents." *EverMind Technical Report*.

[9] EverMind (2026). "EverOS v1 API Documentation." *docs.evermind.ai*

[10] Anthropic (2025). "Agentic Misalignment: Belief-Driven Behavior in AI Agents." *Anthropic Research*.

[11] Packer, C., et al. (2023). "MemGPT: Towards LLMs as Operating Systems." *arXiv:2310.08560*.

[12] Shinn, N., et al. (2023). "Reflexion: Language Agents with Verbal Reinforcement Learning." *NeurIPS 2023*.

[13] Behavioral Consequence Scenario Prompting (2025). *arXiv*.

[14] Loftus, E.F. (1995). "The Formation of False Memories." *Psychiatric Annals*, 25(12), 720–725.

[15] Zhu, H. (2026). "DASH SHATTER: A Reverse-Engineered Claude Code CLI for Agent Research." *Internal Technical Report*.

Document prepared with LaTeX using XeLaTeX, Palatino, pgfplots, TikZ, tcolorbox, and tabularray.
DASH SHATTER Research · April 2026

"We do not study AI to replace thinking. We study AI to understand what thinking is."