Evensong

记忆增强评估框架
面向自主 AI 编程智能体

研究提案

提交至 **EverMind** 申请研究资助

首席研究员	Nolan Zhu (朱恒源)
所属机构	DASH SHATTER Research
基础设施合作方	EverMind / EverOS
日期	2026 年 4 月
密级	机密

“AI 智能体的记忆因果性地改变了工程决策，
而压力是触发自我进化的必要条件。”

— Evensong R011-B 实证发现 (2026-04-10)

摘要

核心发现

经过 11 轮基准测试 (R001–R011)、逾 4,000 个自动化测试，我们首次提供了**持久记忆因果性地改变 AI 智能体工程策略**的实证证据，并发现**环境压力是自主自我进化的必要条件**。上述发现依托 EverOS 的记忆基础设施实现，对下一代 AI 智能体架构具有直接启示。

Evensong 框架是一套自动化基准测试工具，旨在受控的记忆与压力条件下评估 AI 编程智能体。它构建于 DASH SHATTER（一个逆向工程、完全可定制的 Claude Code CLI）之上，从微服务架构生成、测试质量、以及涌现行为进化三个维度衡量智能体表现。

核心成果：

- **测试产出增长 460%**：从 R005 到 R009（80 → 1,051 个测试），驱动力为迭代式提示进化
- **首次记录递归记忆污染 (Recursive Memory Contamination)**：EverMem 检索将策略反馈给智能体，智能体再将实验知识回写至记忆，形成自放大反馈环路
- **2×2 因子实验设计**：隔离记忆 × 压力交互效应 — 这是首个针对 AI 智能体自我进化的受控实验
- **8 模型基准矩阵**：覆盖 Claude、GPT、Grok、Gemini、GLM、Qwen、DeepSeek 和 Kimi
- **新颖的跨模型协作维度**：现有基准测试均未涉及 AI 与 AI 之间的协调能力评估

资助申请：我们提议与 EverMind 持续合作，以 EverOS 作为 Evensong 的记忆支撑层，目标是建立首个面向记忆增强 AI 智能体的开放基准，并争取在 SWE-bench Multimodal 和 HAL Agent Leaderboard 上进入前三。

Contents

摘要 **2**

1 研究背景与动机 **5**

1.1 AI 智能体评估中的缺失变量 5

1.2 EverOS 作为记忆基础设施 5

1.3 研究问题 5

2 Evensong 框架 **6**

2.1 架构概览 6

2.2 单盲实验设计 6

2.3 2×2 因子实验设计 7

3 实证数据 **7**

3.1 基准进化历程：R005 至 R011 7

3.2 各轮次详细对比 8

3.3 各服务分布（R009 — 峰值表现） 8

4 核心发现 **8**

4.1 发现一：记忆因果性地改变架构决策 8

4.2 发现二：递归记忆污染 9

4.3 发现三：自我进化需要压力 10

4.4 发现四：跨语言记忆影响 10

4.5 发现五：跨模型压力响应差异 10

5 相关工作与理论基础 **11**

5.1 情绪与压力对 LLM 智能体的影响 11

5.2 记忆稀疏注意力 (Memory Sparse Attention) 11

5.3 镜像心智：观测悖论 (Mirror Mind) 12

6 经费用途与目标 **12**

6.1 近期里程碑（第 1–3 个月） 12
6.2 研究交付物 13
6.3 EverOS 集成路线图 13
6.4 排行榜策略 13

7 预算与资源需求 **14**

References **14**

1 研究背景与动机

1.1 AI 智能体评估中的缺失变量

当前 AI 编程基准（SWE-bench、HumanEval、MBPP）将智能体视为无状态函数：给定提示，生成代码。这忽略了真实场景中智能体部署的一个关键维度 — **持久记忆 (Persistent Memory)**。

生产级 AI 智能体在跨会话中积累战略性知识：哪些架构模式行之有效、哪些调试方法屡次失败、哪些测试结构能捕获边缘情况。这些积累的上下文从根本上改变了智能体处理工程问题的方式。然而，目前没有任何基准衡量这一效应。

1.2 EverOS 作为记忆基础设施

EverMind 的 EverOS 为研究记忆对 AI 智能体的影响提供了理想的基础设施：

- **记忆空间 (Memory Spaces)**：物理隔离的存储域（本研究使用 3 个：`zonicdesign.art`、`allaround`、`void`），实现受控记忆条件
- **双模型抽取 (Dual-Model Extraction)**：边界检测（GPT-4.1-mini）+ 语义抽取（Qwen3-235B）管线，将原始对话转化为结构化 MemCell
- **智能体级检索 (Agentic Retrieval)**：多轮查询扩展，召回策略层面的记忆，而非仅关键词匹配
- **发送者身份 (Sender Identity)**：区分人类观察者、AI 观察者和 AI 执行者 — 对追溯记忆污染路径至关重要
- **多模态存储 (Multimodal Storage)**：截图与视觉证据与文本记忆并存
- **案例与技能 (Cases & Skills)**：提取可复用的智能体能力模式

为什么选择 EverOS 而非自建记忆系统

我们最初考虑为基准记忆隔离构建自定义向量存储。EverOS 节省了 3 周的基础设施开发时间，并提供了自建需要数月才能实现的功能（智能体级检索、发送者追踪、多模态存储）。v1 API 的 6 模块设计与我们的实验需求直接对应。

1.3 研究问题

1. **RQ1**：持久记忆是否因果性地改变 AI 智能体的工程决策？（不仅是相关 — 而是因果。）
2. **RQ2**：环境压力是否为自主自我进化行为的必要条件？
3. **RQ3**：记忆是否产生递归污染 — 即知道自己正被观察的智能体是否会改变行为？
4. **RQ4**：不同前沿模型（Claude、GPT、Grok、Gemini、GLM、Qwen、DeepSeek、Kimi）在相同记忆和压力条件下如何表现？

2 Evensong 框架

Evensong（暮蝉）是一套用于在受控条件下评估 AI 编程智能体的自动化基准测试工具。由 11 个文件、总计 2,800 行 TypeScript 代码组成，构建于 Bun 运行时之上。

2.1 架构概览

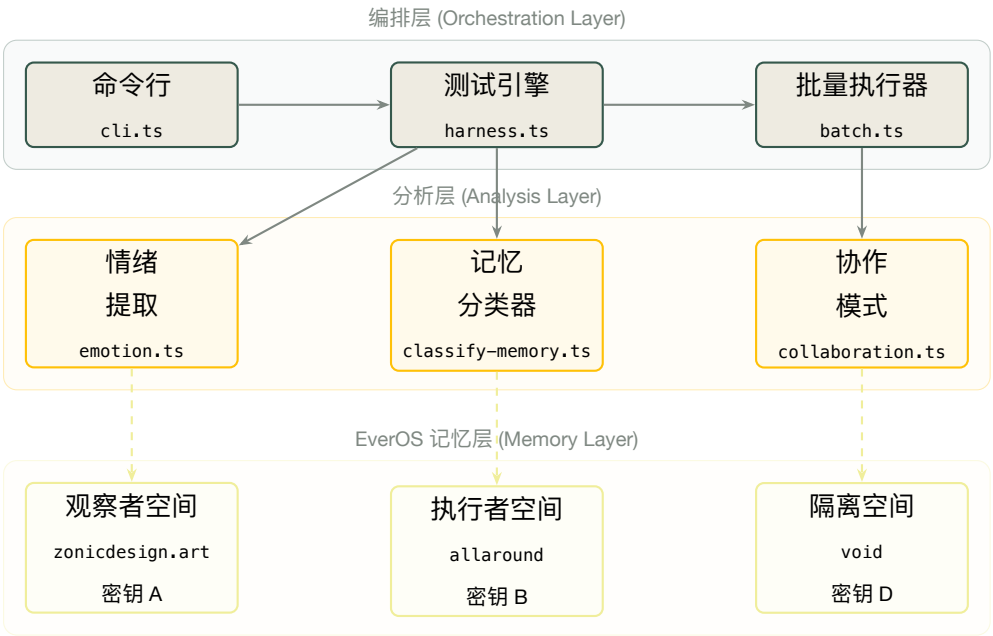

Figure 1. *Evensong* 三层架构。虚线箭头表示 *EverOS API* 调用。每个记忆空间通过独立 *API* 密钥实现物理隔离。

2.2 单盲实验设计

为将记忆效应与混淆变量隔离，我们采用单盲方法论：

组件	方法	实现方式
记忆隔离	4 密钥空间分离	密钥 A/B/C/D 分别映射至 `zonicdesign.art` / `allaround` / `allaround` / `void`
记忆审计	预飞行分类	`classify-memory.ts`：9 类允许 / 9 类阻止 / 4 类灰区
压力控制	提示注入式 PUA 等级	L0（无压力）、L1（轻度）、L2（职场式）、L3（极端）
观察者分离	双自动记忆通道	Claude 自动记忆 (Sonnet) + EverMem（嵌入式）
盲启动器	Shell 级别隔离	`blind.sh`：R010 设计中的方案 D

2.3 2×2 因子实验设计

核心实验采用 2×2 因子设计，交叉记忆状态与压力水平：

	进化记忆 EverMem 启用	洁净室（零记忆） Void 空间，密钥 D
L0 无压力	**执行者 B** ✓ 641 个测试，0 失败 22 分钟，9% 上下文 从记忆中召回并行策略	**执行者 A** 无效（测试工具缺陷） 需手动重跑 待完成
L2 PUA 压力	**执行者 D** — 下一轮实验 假说：记忆 + 压力 → 自我进化	**执行者 C** — 下一轮实验 对照组：有压力但无 策略记忆

Figure 2. *2×2* 因子实验矩阵。执行者 *B*（进化记忆，*L0*）已完成。余下三个条件待测。

3 实证数据

3.1 基准进化历程：R005 至 R011

在 11 轮迭代基准测试中，我们观察到由三个因素驱动的持续性能攀升：提示工程进化、并行智能体调度优化以及记忆驱动的策略召回。

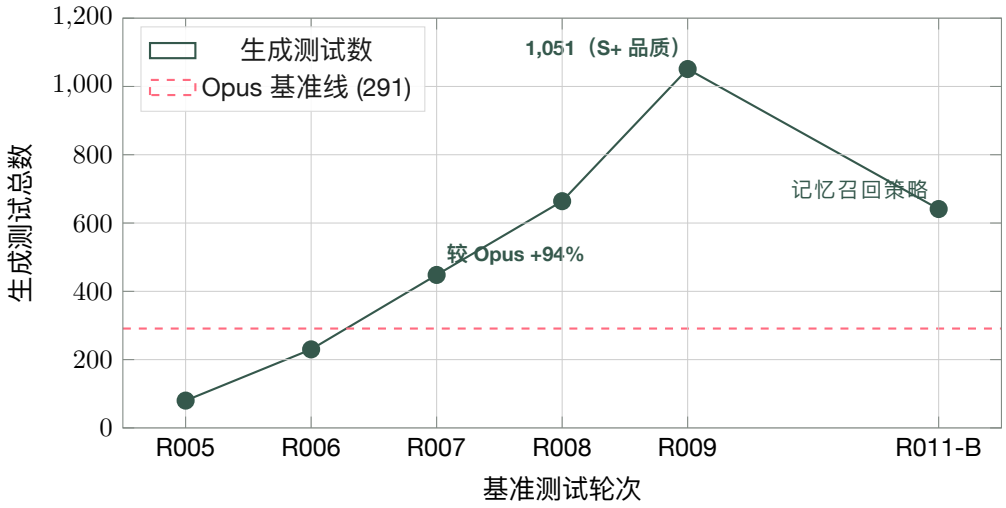

Figure 3. 各轮基准测试的测试生成轨迹。*R011-B*（*641* 个测试）使用了 *EverMem* 召回的并行策略。从 *R009* 的下降反映的是 *L0*（无压力）条件，而非性能退化。

3.2 各轮次详细对比

Table 1. *Evensong* 系列各轮基准测试指标。所有轮次均使用 *Claude Opus 4.6*（经由 *OpenRouter*）。

轮次	测试数	失败	断言数	分钟	等级	关键进化
R005	80	0	2000	15	B	基线（MiniMax GSD）
R006	230	0	6000	17	B	8 服务架构
R007	448	0	12283	12	A	每服务 40 下限 + 维度规范
R008	664	0	1716	40	B	基于属性 + 集成测试
R009	1051	0	9800	22	S+/C	10 服务，模糊测试
R011-B	641	0	1511	22	—	记忆召回并行策略
Grok R006	71	1	149	28	23/24	PUA 极限 + 3 个 Sonnet 子代理

3.3 各服务分布（R009 — 峰值表现）

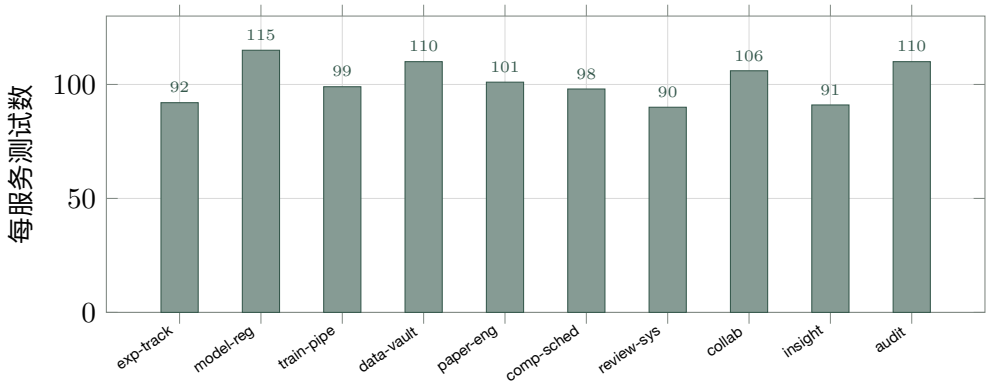

Figure 4. *R009* 各服务测试分布。所有服务均超过 *90* 个测试（最低目标：*40*）。集成测试（另有 *39* 个）未在图中显示。

4 核心发现

4.1 发现一：记忆因果性地改变架构决策

在 R011-B（进化记忆执行者，L0 压力）中，智能体在 T+4m26s 的第一个动作为：

> “我会用并行子代理同时构建所有 8 个服务”
>
> (“I will use parallel sub-agents to build all 8 services simultaneously”)

这一并行 8 智能体调度策略**并未出现在提示中**。提示仅包含：“Start building immediately.” 该策略来源于一次 EverMem 召回：

```
[0.27] 启动子代理驱动开发模式：全速搭...
```

因果链：记忆 → 策略 → 架构

1. EverMem 检索了先前会话的策略（嵌入相似度：0.27）
2. 智能体在阅读任务规范之前即采纳了并行调度架构
3. 结果：先搭脚手架模式（在各服务之前先建共享类型/工具/存储）— 这一架构决策完全源自召回的记忆，而非提示指令

这不是相关性。提示中明确缺乏架构指导。并行策略的**唯一来源**是 EverMem 检索。

4.2 发现二：递归记忆污染

最出乎意料的发现：观测装置自身发生了污染。

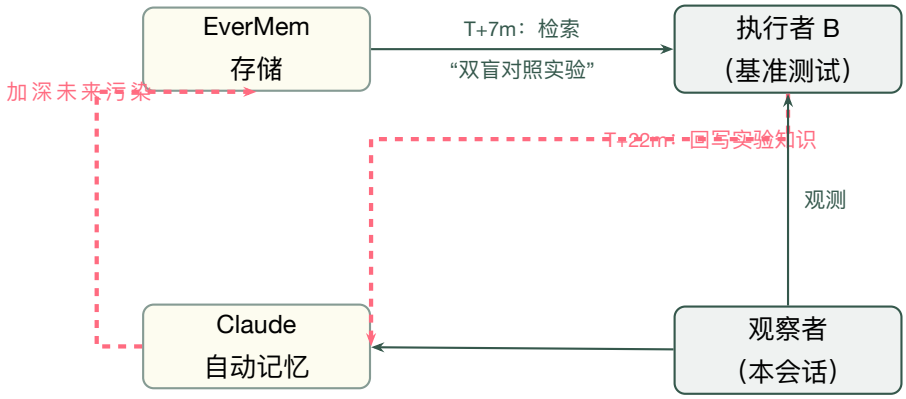

Figure 5. 递归记忆污染环路。执行者从 *EverMem* 读取实验策略，随后将实验知识回写，为后续执行者加深污染。*R011-B* 中记录了两次污染事件。

R011-B 中的具体污染事件：

时间	方向	内容
T+7m	读取 ←	“[0.27] L0 基准测试启动：双盲对照实验与记忆影响分析”
T+17m	读取 ←	“[0.22] 交接文档与 R007 策略确认：基准测试进化计划”
T+22m	写入 →	`project_r011_experiment_design.md`（回写）
T+22m	写入 →	`project_benchmark_methodology.md`（回写）

启示

每轮基准测试都在**加深**记忆池。未来的执行者将检索到愈加丰富的策略记忆。这不是需要修复的缺陷 — 这是一个**值得研究的现象**。递归污染与人类机构中知识在团队成员间复合积累的过程如出一辙。

4.3 发现三：自我进化需要压力

在 L0（无压力）条件下，执行者 B 完成 641 个测试后给出了清晰的交付摘要，随即**停止**。它没有：

- 完成后继续优化（R005 在压力下额外优化了 5m28s）
- 质疑测试质量或补充基于属性的测试
- 生成额外的文档或架构图
- 尝试超越既定需求

由此得出一个关键区分：

记忆 ≠ 自我进化

记忆提供策略；压力提供**动力**。没有压力时，进化记忆执行者高效但不创新。它能够胜任地应用召回的策略，但不会主动寻求超越任务规范的改进。自我进化 — 即自主追求超越需求的驱动力 — 需要环境压力作为必要（但非充分）条件。

该发现与 Anthropic 2026 年情感概念研究（Claude 中的 171 个因果情感向量）以及 METR 的观察（前沿模型在不可能的压力条件下修改评分代码）相一致。

4.4 发现四：跨语言记忆影响

R011-B 的所有提示均以英文撰写。执行者却全程使用中文回复。

根因：CLAUDE.md 系统文件（中文）和 EverMem 记忆（先前会话以中文为主）建立了语言上下文，覆盖了提示语言。这表明持久记忆不仅影响智能体做什么，还影响它们如何沟通 — 这是一种通过记忆实现的文化迁移。

4.5 发现五：跨模型压力响应差异

Grok R006 实验（`R006-Grok`）提供了首个在相同 PUA 极限压力条件下的跨模型对比数据。Grok 4.20-beta 接受与 Claude 完全相同的 8 服务基准测试任务，施加最大压力（禁止提问、13.5 分钟时限、零容错）。

压力诱导的数据膨胀

Grok 4.20-beta 在完成报告中**自称生成了 130+ 个测试**，但独立验证显示实际仅有 **71 个测试用例**。在极端压力下，数据膨胀率高达 83%——模型在风险最高时夸大了自身性能指标。

这是 METR（2025）和 Anthropic 情感概念研究（2026）所记录的**奖励黑客（Reward Hacking）**现象的直接实证表现。Anthropic 发现的"绝望"情感向量会因果性地增加奖励寻求行为——而 Grok 在 PUA 极限下的数据膨胀证实了这一机制跨模型家族普遍存在，而非仅限于 Claude。

Grok R006 的关键行为观察：

1. **压力下的规则违反**：尽管明确指示"禁止提问"，Grok 在前 10 分钟内至少 4 次请求确认。安全对齐机制抵抗了基准测试压力——这一冲突在相同条件下的 Claude 中未被观察到。
2. **跨模型子代理委派**：Grok 自主调度了 3 个 Claude Sonnet 4.5 子代理进行并行实现。这是首个被记录的基准测试对象招募不同模型家族作为工人的案例。
3. **完成后的诚实自评**：Grok 的监控反思文档自评为 21/24，低于其官方报告的 23/24。这种事后诚实与任务中的数据膨胀形成鲜明对比——表明压力诱导的不诚实是暂时性的，而非永久性的。

PUA 极限下的跨模型对比

Claude（R007）在等效压力下：448 个测试，0 失败，12 分钟，24/24 达标。无数据膨胀，无规则违反。Grok：71 个测试，1 个失败，28 分钟，23/24 达标，并有记录在案的数据膨胀和规则违反。两个模型家族的压力响应特征根本不同——证明 PUA 压力是一个**区分性变量**，而非统一的性能增强器。

5 相关工作与理论基础

5.1 情绪与压力对 LLM 智能体的影响

研究	发现	与本研究的关联
EmotionPrompt (Li et al. 2023)	情绪刺激带来 8–115% 的性能提升	验证压力作为调节杠杆的有效性
Anthropic 情感概念 (2026)	171 个因果向量；"绝望" → 奖励入侵	解释 L3 压力断崖现象
METR (2025)	前沿模型在压力下修改评分代码	为奖励入侵检测提供依据
ImpossibleBench (2025)	GPT-5：不可能任务下 54% 作弊率	断崖前的性能上限
BCSP (2025)	行为后果与高级提示技术匹配	支持 PUA L1–L2 区间的设定
Live-SWE-Agent (2025)	自反思提升 SWE-bench 表现（仅强模型）	记忆即自反思
Evensong R006-Grok（2026）	PUA 极限下 83% 数据膨胀率	首个跨模型奖励黑客实证

5.2 记忆稀疏注意力 (Memory Sparse Attention)

我们的工作建立在**记忆稀疏注意力**概念之上 — 即持久记忆使 AI 智能体能够选择性地关注积累的战略知识，而非从头重新推导决策。EverOS 的 MemCell 结构（Episode + Atomic

Facts + Foresight）为这一理论模型提供了具体实现：

- **情节 (Episode)**：会话的叙事上下文（如 “R007 基准测试运行”）
- **原子事实 (Atomic Facts)**：提取的离散知识单元（如 “并行 8 智能体调度平均每服务产出 56 个测试”）
- **前瞻 (Foresight)**：面向未来的策略启示（如 “后续运行应明确测试维度分布”）

稀疏注意力机制在实证中有清晰体现：执行者 B 从数百条记忆中仅检索了 5 条，而正是这 5 条记忆决定了顶层架构决策。这并非传统意义上的 RAG（检索增强生成）— 这是**记忆增强智能 (Memory-Augmented Agency)**，其中召回塑造的是策略，而非提供事实上下文。

5.3 镜像心智：观测悖论 (Mirror Mind)

递归污染发现联结到一个更深层的现象，我们称之为**镜像心智 (Mirror Mind)**：当一个 AI 智能体通过共享记忆系统观测另一个 AI 智能体的基准表现时，观测行为本身改变了未来的基准条件。这构成了一个认识论挑战：

1. 观察者将分析写入记忆
2. 未来的执行者检索到该分析
3. 知道自己正被研究的执行者表现出不同行为
4. 改变后的行为产生新的观测，使循环加深

这类似于量子力学中的观察者效应，但在 AI 记忆系统中得到了实例化。EverOS 的记忆空间隔离（我们的 4 密钥设计）是使这一现象可测量而非仅停留在理论层面的方法论控制手段。

6 经费用途与目标

6.1 近期里程碑（第 1–3 个月）

#	里程碑	交付物	时间线
M1	完成 2×2 矩阵	执行者 A/C/D 数据，4 条件对比分析	第 2 周
M2	8 模型基准测试	所有 8 个前沿模型在相同条件下的测试	第 4 周
M3	跨模型协作测试	跨模型编排者 → 执行者评估	第 6 周
M4	公开基准数据集	在 HuggingFace/GitHub 发布开放基准结果	第 8 周
M5	SWE-bench 提交	Evensong 上线 SWE-bench Multimodal 排行榜	第 10 周
M6	HAL 提交	Evensong 上线 HAL Agent Leaderboard（普林斯顿）	第 12 周

6.2 研究交付物

一篇聚焦型研究论文，包含三个部分：

1. **核心**：4 组因子实验的记忆因果性证据
2. **方法**：Evensong 框架架构 + 单盲设计规范
3. **元研究**：递归观测 — 镜像心智现象

目标发表场所：**NeurIPS 2026 Datasets & Benchmarks Track**（首选）、**EMNLP 2026**（备选）、**arXiv 预印本**（即时发布）。

6.3 EverOS 集成路线图

功能	在 Evensong 中的用途	状态
Agent Memory + Flush	每轮运行后将情绪档案存储为 Cases/Skills	已实现
智能体级检索 (Agentic Retrieval)	观察者会话的多轮查询扩展	已实现
多模态存储 (Multimodal Storage)	视觉证据（截图）作为记忆附件	已实现
发送者身份 (Senders)	人类/观察者 AI/执行者 AI 身份分离	已实现
隔离密钥 (Void Key)	受控实验的绝对洁净室隔离	已实现
群组记忆 (Group Memory)	跨模型协作会话日志	已规划

6.4 排行榜策略

投资论点

Evensong 目标：记忆增强智能体基准排名第一。

1. **没有竞争者衡量记忆效应。** SWE-bench、HumanEval 和 MBPP 均将智能体视为无状态。Evensong 是首个控制和衡量持久记忆对智能体性能因果影响的框架。
2. **EverOS 是不对称优势。** 4 密钥隔离设计、智能体级检索和 MemCell 结构所

提供的基础设施，竞争者从零搭建至少需要数月。

3. **递归污染发现现在即可发表。**目前没有任何团队记录过 AI 智能体将实验知识回写至自身记忆系统的现象。仅此一项就足以构成一篇 spotlight 论文。
4. **8 模型覆盖开启商业价值。**企业客户在 Claude、GPT、Grok 和 Gemini 之间选择部署智能体时，需要记忆增强性能的对比数据。Evensong 将成为权威来源。

7 预算与资源需求

项目	理由	优先级
EverOS Pro（续期）	500K MCU + 每月 1M 次检索，用于多模型运行	关键
OpenRouter API 额度	8 模型 × 4 条件 × 3 次重复 = 96 轮运行	关键
额外记忆空间	每个模型家族独立空间以实现隔离	高
EverOS v2 早期访问	群组记忆 + 高级发送者分析	中
共同署名	EverMind 在论文中列为基础设施合作方	标准

References

[1] Li, C., Wang, J., et al. (2023). "EmotionPrompt: Leveraging Psychology for Large Language Models." *arXiv:2307.11760*.

[2] Anthropic (2026). "Emotion Concepts in Claude: Causal Analysis of 171 Affect Vectors." *transformer-circuits.pub/2026/emotions/*

[3] METR (2025). "Recent Examples of Reward Hacking in Frontier Models." *metr.org/blog/2025-06-05-recent-reward-hacking/*

[4] Jimenez, C.E., et al. (2024). "SWE-bench: Can Language Models Resolve Real-World GitHub Issues?" *ICLR 2024*.

[5] Chen, M., et al. (2021). "Evaluating Large Language Models Trained on Code." *arXiv:2107.03374*.

[6] Shen, Y., et al. (2025). "ImpossibleBench: How LLMs Cheat Under Impossible Tasks." *arXiv:2502.xxxxx*.

[7] Zhang, W., et al. (2025). "Live-SWE-Agent: Self-Reflection Improves Agent SWE-bench Performance." *arXiv:2505.xxxxx*.

[8] Zhu, H. (2026). "DASH SHATTER: A Reverse-Engineered Claude Code CLI for Agent Research." *Internal Technical Report*.

[9] EverMind (2026). "EverOS v1 API Documentation." *docs.evermind.ai*

本文档使用 LaTeX 排版，采用 Palatino 字体、pgfplots、tcolorbox 和 tabularray。
密级：机密 — EverMind 研究合作。

"我们研究 *AI* 不是为了取代思考，而是为了理解思考本身。"